

스터디 소개

본 스터디에서는 머신러닝/AI 프로젝트의 첫 단계인 탐색적 데이터 분석을 함께 배우고 실습하는 것을 목표로 했습니다.

해당 분야에 대해 처음 공부하는 것이었기에 '프로젝트로 배우는 데이터 사이언스', '캐글 실습으로 배우는 데이터 사이언스' 강의와 실습 과제를 바탕으로 스터디를 진행했습니다.

스터디는 각자 정해진 기간 내에 강의를 수강하고 강의 내용에 대해 함께 토의하는 방식으로 진행하였습니다.

주제 소개

본 스터디에서는 전반적인 데이터 분석 파이프라인을 주제로 다루었습니다.

먼저 EDA(탐색적 데이터 분석)를 통해 데이터의 크기와 구조를 파악하고, 결측값 및 이상치를 확인하는 과정을 거쳤습니다. 또한 변수 간 분포와 상관관계를 시각화하여 모델 학습에 앞서 데이터의 특성을 깊이 이해하였습니다.

이후 Feature Engineering 단계에서는 범주형 변수를 수치형으로 변환하는 Label Encoding과 One-Hot Encoding, 피처 간 값의 범위를 통일하는 Scaling, 그리고 결측값 처리 방법을 학습하며 모델이 데이터를 효과적으로 학습할 수 있는 환경을 구성하였습니다.

마지막으로 Regression Model 단계에서는 Train/Test 데이터 분리, K-Fold 교차 검증, MAE·RMSE 기반 성능 평가, RandomizedSearchCV를 활용한 하이퍼파라미터 근사 탐색, 잔차 그래프 시각화까지 모델 구축의 전 과정을 실습하였습니다.

실습 데이터로는 혈당, BMI, 나이 등 건강 수치 기반의 당뇨 예측 데이터셋을 활용하여, 실제 데이터에 분석 파이프라인을 직접 적용하며 각 단계의 역할과 흐름을 체계적으로 익혔습니다.

EDA를 통한 데이터 탐색

[Dataset Overview]

- 데이터 크기, 변수 구성, 예측 대상 Outcome 확인

[Missing Value Check]

- 결측치 여부와 측정값으로 보기 어려운 0값 확인

[Target Distribution]

- 정상/당뇨 데이터 비율 시각화를 통한 클래스 분포 확인

[Feature Distribution]

- 혈당, BMI, 나이 등 주요 변수의 분포 및 이상치 가능성 확인

[Outcome Comparison]

- 당뇨 여부에 따른 주요 변수의 분포 차이 비교

[Correlation Analysis]

- 상관계수를 활용한 변수 간 관계와 주요 변수 파악

[EDA Summary]

- Feature Engineering과 모델 학습을 위한 데이터 특성 파악

Regression Model

[Data Split]

- Train(학습)과 Test(평가) 데이터셋을 분리하여 모델의 과적합을 방지

[Cross Validation]

- K-Fold 기법을 적용하여 데이터를 K개의 fold로 분할 후 교차 검증함으로써 모델 성능의 일반화 능력을 추정

[Evaluation Metrics]

- MAE: 실제 정답 수치와 모델 예측값 사이의 절대적 오차 평균을 계산
- RMSE: 오차 제곱 평균에 루트를 씌워 아웃라이어에 페널티 부여


[Hyperparameter Tuning]

- RandomizedSearchCV 알고리즘으로 무작위 샘플링 탐색을 통해 제한된 리소스 내에서 오차를 최소화하는 하이퍼파라미터 조합을 효율적으로 근사 탐색

[Residual Analysis]

- 학습 완료 후 실제 정답과 예측값의 차이인 잔차 그래프를 시각화

Feature Engineering



[Label Encoding]

- 범주형 데이터에 정수를 부여. 순서가 있는 데이터에 적합
- 빨강→0, 파랑→1, 초록→2

[One-Hot Encoding]

- 각 범주를 별도의 0/1 컬럼으로 변환. 순서 없는 범주에 적합
- 빨강→[1,0,0], 파랑→[0,1,0], 초록→[0,0,1]

[Scaling]

- 피처 간 값의 범위를 통일하여 모델 학습 안정화
- Min-Max: 0~1 사이로 압축
- Standard: 평균 0, 표준편차 1로 변환

[Missing Value]

- 데이터에 빠진 값을 적절히 채우거나 제거하는 작업
- 평균/중앙값으로 대체(수치), 최빈값으로 대체(범주), 행 삭제