

AI System 스터디 2팀

박준우, 양희원, 이나현

마이

스터디 소개

AI System 스터디에서는 매주 월요일 대면으로 모여 nano-vllm codebase 분석, Prefill/Decode Disaggregation, Speculative Decoding, Mixture of Expert Inference Serving 등 LLM Inference 관련한 논문과 자료를 읽어와 서로 설명 및 질의응답하는 방식으로 진행하였습니다.

주제 소개


LLM을 비롯하여 AI가 다양한 서비스에 도입되면서 모델의 학습과 성능뿐만 아니라 추론 비용, 처리량, 지연 시간, GPU 메모리 사용량, 서빙 아키텍처가 매우 중요한 문제로 떠오르고 있습니다.

본 스터디에서는 LLM Inference를 중심으로 AI System과 관련된 다양한 주제를 다루었습니다. 최신 논문과 article들을 바탕으로 Inference에 어떠한 병목과 비용이 있고 이를 효율화하기 위해 어떠한 방법이 고안되었는지 을 함께 분석하였습니다.

활동 내용

- nano-vllm codebase 분석
- GPU and CUDA basics
- Orca, PagedAttention paper review
- SplitWise, DistServe, Sarathi-Serve paper review
- Speculative Decoding, MEDUSA, and EAGLE series paper review
- MoE Inference Economics From First Principles article review, Mixtral of Experts paper review

MoE Inference



Transformer block에는 Self Attention, FFN이라는 두 가지 핵심적인 component 가 있다.


Mixture of Experts architecture에서도 Self Attention은 Dense model과 마찬가지로의 방식으로 진행된다. 그러나 FFN을 sparse하게 사용한다는 점이 Dense model과 다르다.

Why Multi-node Scaling?

1) MoE 모델의 memory capacity 부담이 매우 크다.


GPU node란 CPU, RAM, NIC, local storage와 여러 장의 GPU chip을 가진 물리적 서버이다. 대체로 8-GPU server 형태의 node가 보편적이다. 이때 H100 GPU 기준 VRAM은 80GB이고 single node VRAM은 640GB이다. DeepSeek-V3.1 671B 모델의 경우 fp8로 serving을 한다고 하더라도 모델 가중치만 올려도 하나의 노드를 넘어선다. KV cache와 activation memory까지 고려할 경우 multi-node scaling이 불가피하다.

2) MoE 모델은 Expert Parallelism을 통해 더 많은 node를 사용할수록 더 경제적이고 효율적으로 token을 출력할 수 있다.



x축: token per second y축: token per token per request (latency 관련)
Expert Parallelism은 expert를 축으로 GPU에 분담하는 방식으로 MoE에서 선호되는 병렬화 방법이다. 그래프에서 보이듯 더 높은 EP number를 사용할수록 각 GPU에 할당되는 Expert이 줄어들기 때문에 각 GPU는 forward pass를 할 때 더 적은 FFN weight을 읽어도 된다. 이는 처리량(throughput)과 지연시간(latency) 두 가지를 모두 개선한다. 따라서 memory capacity 부담이 아니더라도 일반적으로 GPU node 수를 늘리면 더 경제적인 serving이 가능해진다.

Speculative Decoding



배경: LLM의 토큰 생성은 메모리 대역폭(Memory Bandwidth) 병목으로 인해 지연 시간(Latency)이 길다.

동작 방식:

추측 (Drafting): 작고 빠른 'Draft Model'이 다음 여러 토큰을 빠르게 예측한다.

검증 (Verification): 크고 정확한 'Target Model'이 예측된 토큰들을 한 번에 병렬 검증하여 채택한다.

효과: 타겟 모델 단독 사용 시와 100% 동일한 품질(Lossless)을 유지하면서, 디코딩 속도를 2~3배 이상 획기적으로 가속

PagedAttention



LLM inference에서 throughput을 늘리기 위해 가장 간단한 방법은 batching을 더 많이 하는 것이다. Batching을 더 많이 하기 위해서는 model weight와 activation memory를 제외한 공간인 KV cache를 위한 메모리 공간을 효율적으로 사용하는 것이 중요(위 그림 참고)하다.

Orca와 같은 이전 시스템의 경우 모든 prompt마다 최대 크기의 메모리 공간을 제공하여 실제로 token의 KV cache가 저장된다는 보장이 없지만 메모리가 할당되는 비효율적인 방식을 사용하였다.. 이 때문에 제대로 사용하는 KV cache는 전체 가능한 메모리의 20%뿐이 사용되지 못했다. PagedAttention은 모든 token의 KV cache를 B(ex. B=16) size의 block으로 설정하고 낭비가 될 수 있는 최대 토큰 수를 B-1로 제한하였다. 이 방식을 통해 가능한 memory capacity 중 96%를 사용할 수 있었고 batch 수를 매우 늘려 token efficiency를 높였다.

