

스터디 소개

본 스터디는 AI System에 대해 이해하는 것을 목표로 진행했습니다.

AI System의 기초부터 공부하기 위해 쉽게 시청할 수 있는 Stanford CS149 Parallel Computing 강의와 함께 제공되는 강의 자료를 참고하여 병렬 컴퓨팅에 대한 기본 개념과 응용을 공부했습니다.

각자 강의를 듣고 내용을 정리해와서 스터디 조원들과 함께 토의하는 방식으로 진행했습니다.

주제 소개

본 스터디에서는 현대 AI 시스템의 성능을 극대화하기 위한 병렬 컴퓨팅(Parallel Computing)의 핵심 원리와 하드웨어 최적화 기법을 학습했습니다.

단순히 AI 모델을 학습시키는 것을 넘어, 하드웨어 구조에 대입해 연산 효율을 극대화하는 방법을 중심으로 공부했습니다.


CPU 수준에서의 가속을 위한 SIMD(Single Instruction Multiple Data) 구조와 Masking 제약을 시작으로,

GPU 환경에서 대규모 행렬 연산을 가속화하는 GEMM Optimization 기법(NVIDIA CUTLASS, Triton)을 분석했습니다.


또한 Transformer 및 DNN 모델이 GPU와 전용 AI 가속기(NPU) 환경에서 효율적으로 실행되기 위한 데이터 흐름과 Layer Fusion 등의 최적화 기법을 학습하며,

하드웨어와 소프트웨어를 아우르는 AI 시스템 역량을 길렀습니다.

SIMD



GEMM Optimization




NVIDIA CUTLASS

- Fast (in-shared memory) GEMM
- Fast WARP level GEMMs
- Iterators for fast block loading/tensor indexing
- Tensor reductions

Triton

- Language support for operations that load/store tensors
- Load "blocks" of data into GPU shared memory
- Perform data-parallel operations on those blocks

GPU Parallelism & AI Acceleration



CUDA Hierarchy & Mapping

Thread-Block-Grid 계층 구조를 통해 대규모 코어 연산 분산 및 매핑.

Memory Hierarchy Optimization

Shared Memory 및 Global Memory(DRAM) 대역폭 병목 최소화

Model-Level Scaling

Layer Fusion 및 전용 AI 가속기(NPU)를 통한 대규모 AI 모델 연산 가속