

스터디 소개

본 스터디에서는 **Computer Vision** 분야의 대표적인 논문들을 함께 읽고 토론하며, 현대 CV 연구의 핵심 흐름인 **Representation Learning, Foundation Model, Generative Model**에 대한 이해를 목표로 합니다.

스터디는 총 **3명**이 모여 **6회**에 걸쳐 진행되었으며, 매주 발표자는 사전에 논문을 정독하고 **발표자료(PPT)**를 제작하여 공유하였으며, 발표 이후 자유로운 토론을 통해 핵심 아이디어와 한계점을 함께 정리하였습니다.

주제 소개

최근 Computer Vision은 **Transformer 기반 모델**의 등장과 함께 거대한 패러다임 전환을 맞이하고 있습니다. 본 스터디에서는 이 흐름을 크게 세 갈래로 나누어 살펴 보았습니다.


① **Foundation Models** — 대규모 데이터로 사전학습 되어 다양한 downstream task에 zero/few-shot으로 활용 가능한 범용 모델 (CLIP, SAM)

② **Self-Supervised Learning** — 라벨 없이 이미지 자체에서 supervisory signal을 만들어 학습하는 표현 학습 방법론 (MAE, I-JEPA, ViT Registers)

③ **Generative Models** — 데이터 분포를 학습하여 새로운 이미지를 생성하는 모델, 특히 Transformer를 활용한 Diffusion (DiT)

① Foundation Models

[CLIP]



4억 쌍의 **(image, text)** 데이터로 **Contrastive Learning** 수행. Image/Text encoder를 통해 같은 pair는 가깝게, 다른 pair는 멀어지도록 embedding space를 정렬.

→ **Zero-shot classification**: "a photo of a [class]" prompt만으로 fine-tuning 없이 강력한 성능. Vision-Language Foundation Model의 출발점.

[SAM]




Segmentation 분야의 **Foundation Model**. Point/Box/Mask 등 다양한 prompt로 즉시 mask를 출력하는 **promptable segmentation** task를 제안.

② Self-Supervised Learning


[MAE]

이미지 patch의 일부를 mask하고, visible patch만으로 가려진 pixel을 복원하는 자기지도학습 방법. Asymmetric encoder-decoder 구조와 높은 masking ratio를 사용해 효율적으로 image representation을 학습




[I-JEPA]

Context block으로 같은 이미지의 target block representation을 예측하는 자기지도학습 방법. Pixel을 복원하지 않고 representation을 예측해 label 없이 semantic image representation을 학습



[ViT Registers]

Self-supervised로 학습된 ViT의 attention map에 나타나는 **artifact (high-norm token)** 문제를 분석. 입력 시퀀스에 학습 가능한 **register token**을 추가하는 단순한 해법으로 dense prediction 성능과 해석 가능성을 모두 개선.



③ Generative Models

[DiT]

기존 Diffusion 모델의 표준 backbone이었던 **U-Net**을 **Transformer로 대체**. Latent space에서 동작하며, **adaLN-Zero** 방식의 conditioning으로 class label과 timestep을 주입. 모델/연산량을 키울수록 FID가 일관되게 개선되는 **scalability**를 입증하여 이후 Sora 등 대규모 생성 모델의 토대가 됨.

