

데이터 분석 및 EDA 스터디 1팀 남동훈 박상현 박현웅 신정민



스터디 소개

저희는 각자의 전공 분야와 관련된 데이터셋에 EDA(탐색적 데이터 분석)와 데이터 분석을 적용함으로써, 전공 지식에 대해 더 깊이 이해하고 유용한 인사이트를 도출하는 활동을 진행하였습니다.

스터디는 매주 화요일 16:30부터 정규 세션 전까지 대면으로 진행하였고, 매주 수행한 스터디 내용을 ALCP 활동보고서를 통해 체계적으로 정리하였습니다.

EDA란? 데이터 분석의 의의

EDA는 탐색적 데이터 분석으로, 모델링이나 가설 검정 이전에 데이터의 구조, 특징, 결측치(값이 비어 있는 경우), 이상치(값이 일반적인 수준을 벗어나는 경우), 변수 간의 관계 등을 통계적 및 시각적으로 파악하는 과정입니다. 원시 데이터는 언제나 불완전합니다. 불완전한 데이터를 학습한 모델은 왜곡된 결과를 도출할 수밖에 없습니다. 그래서 도메인 지식을 바탕으로 한 EDA를 거쳐야, 원시 데이터가 비로소 유용한 데이터로 거듭나게 됩니다. 데이터 분석은 점점 복잡해지는 현대 산업 현장에서 필수적인 방법론입니다.

SK 하이닉스는 반도체 양산 펌에서 발생하는 센서 데이터를 실시간으로 분석하는 가상 계측 AI 솔루션을 핵심 공정에 도입함으로써, HBM의 생산성을 31% 향상시키고, 공정 산포를 평균 21.5%까지 개선하였습니다.

보안 운영 및 분석 플랫폼 기업인 이글루코퍼레이션은 시스템 접근 및 파일 전송 로그를 분석하고 대응하는 보고서를 생성하기까지 40~60분 소요되었지만, 데이터 자동 분석 시스템을 적용하자 2~3분으로 단축시킬 수 있었습니다.

또한 현대 산업 현장에서 속도 경쟁이 불붙은 AI 자동화는 언제나 데이터 분석을 통한 설계를 기반으로 이루어집니다. 저희는 이처럼 기술의 발전에 따라 더욱 그 중요성이 커질 데이터 분석의 관점을 기르고자 했습니다.

남동훈: (UCI SECOM Dataset / 반도체 공정 수율 개선을 위한 EDA)

1. 데이터 전처리 및 범위 설정


- UCISECOM데이터를 활용하여 반도체 공정 센서값과 Pass/Fail 결과를 확인 가능하도록 구성
- Time열, 저분산 변수, 결측치 과다 변수, 중복 변수를 제거하여 분석 범위 축소
- Train/Test 분리 후 Train 데이터의 중앙값으로 결측치 대체

2. 주요 분석 항목

- 결측치 분석: Missing Ratio 기준 결측치 과다 변수 제거
- 상관관계 분석: $\text{corr} \geq 0.90$ 기준 중복 변수 제거
- 집단 차이 분석: Mann-Whitney U 검정으로 Pass/Fail 차이 센서 선별
- 결측치 시지자 분석: χ^2 검정으로 519번 센서 결측 여부 확인
- 이상치 분석: IQR/Robust ES로 동시 이상치 패턴과 불량률 비교

3. 분석 결과

- 저분산 변수 제거 후 591개 → 246개로 변수 감소
- 최종적으로 40개 센서 + 519번 센서 결측 여부가 유의미했으며, 이상치 6개 이상 동시 발생 시 불량률이 23.1%까지 증가함



박상현: (UCI SECOM 데이터를 활용한 반도체 공정 불량 예측 및 데이터 불균형 해소)

1. 데이터 전처리 및 범위 설정


- 590개의 방대한 센서 데이터 중 결측치 50% 이상 변수 및 단일값(표준편차 0) 변수를 제거하여 분석 범위 최적화
- 반도체 장비 특유의 이상치(Outlier)에 의한 왜곡을 방지하기 위해 평균 대신 중앙값(Median)을 활용하여 결측치 보간

2. 주요 분석 항목

- 데이터 스케일링: 서로 다른 센서들의 물리적 측정 단위를 통일하기 위해 StandardScaler 정규화 적용
- 데이터 불균형 해소: 양품(93.4%)과 불량품(6.6%)의 극심한 불균형으로 인한 AI 예측 편향을 막기 위해 SMOTE(합성 소수 다수 샘플링) 기법 도입

3. 분석 결과

- 정보 가치가 없는 노이즈 변수 144개를 제거하여 446개의 핵심 센서 변수로 차원 축소 완료
- 가상의 불량 데이터를 수학적으로 증강하여 양품과 불량률의 비율을 50:50으로 완벽히 동기화, AI 모델이 편향 없이 진정한 불량 패턴을 학습할 수 있는 기반 구축



신정민: 정보 유출 식별 - IP 화이트리스트 / 시스템 접근 권한 / 시스템 접근 로그 / 직원 정보.csv

1. 데이터 전처리 및 범위 설정

- 4가지 데이터 세트를 통합 정제하여 직원별 권한 레벨, 파일 전송 횟수, 전송량 등을 확인 가능하도록 구성
- 파일 전송량 분석을 우선 수행하여 데이터가 없거나 전송량이 극히 적은 직원은 제외

2. 주요 분석 항목

- IP 기반 분석: 승인되지 않은 IP에서의 접근 여부 확인
- 시간 기반 분석: 업무 외 시간대의 접근 탐지
- 파일 전송량 분석: Z-score 및 IQR 통계 활용 → 이상치 탐지 및 동료 대비 전송량 비교
- 권한 초과 시도 분석: 권한 부족으로 차단된 접근, 규칙 위반으로 묵인된 접근 확인
- 접근 사유 코드 분석: 접근 사유가 기록되지 않은 로그 탐지

3. 분석 결과

- 퇴사 예정자 2인에게서 권한 대비 과도한 파일 전송, 퇴사 직전 전송량 급증, 업무 외 시간대 및 미승인 IP에서의 접근 시도 확인

