

Word Vector에서 RLHF까지

Stanford CS224n: NLP with Deep Learning · LLM 학습 파이프라인 정리

● LLM STUDY · 2026

김찬중, 강태혁, 나은성

01 / 스터디 소개


본 스터디는 **Stanford CS224n: NLP with Deep Learning** 강의를 기반으로, **Word Vector** 와 **Neural Network** 등 NLP의 기초 개념부터 최근의 대규모 언어 모델까지 한 학기 동안 학습하였습니다.

매주 정해진 분량의 강의를 시청한 뒤 핵심 개념을 정리하고, 모임에서는 헛갈리는 부분을 공유하며 서로 질문과 답변을 주고받는 방식으로 진행했습니다.

Word2Vec GloVe Neural Net Backprop Dep. Parsing RNN / LSTM
Seq2Seq Attention Transformer Pretraining RLHF

① Supervised Fine-Tuning

STEP 1



Pretrained LM에 **사람이 작성한 답변**으로 supervised fine-tuning을 수행. cross-entropy loss를 최소화하여 **instruction을 따르는 응답 형식**을 학습.

! 한계 — 정답을 사람이 직접 쓰는 비용이 큼. 다음 단계에서 "쓰기" 대신 "비교"를 활용.

③ RLHF · PPO with KL Penalty

STEP 3

CORE OBJECTIVE

$$R(s) = RM_{\phi}(s) - \beta \log \frac{p_{\theta}^{RL}(s)}{p^{PT}(s)}$$

- 1 **RM_φ(s)** — 사람 선호 점수. 이 값을 최대화하도록 정책 p_{θ}^{RL} 을 업데이트한다.
- 2 **-β log(p^{RL}/p^{PT})** — Pretrained 분포에서 멀어지지 않게 막는 **KL Penalty**, 없으면 reward hacking이 일어난다.

최적화는 **PPO**로 수행하며, β가 **보상 극대화** 와 **분포 유지** 의 trade-off를 조절

02 / 발표 주제 소개 — 왜 RLHF인가?

스터디 후반부에 다룬 LLM 파이프라인 중 가장 인상 깊었던 주제는 사람의 선호를 모델에 직접 반영하는 **RLHF** 였습니다.

"정답이 무엇인지" 직접 쓰기는 어렵지만,
"어느 답이 더 좋은지" 비교하는 것은 쉽다.

Pretrained LM은 다음 토큰을 예측할 뿐, 사람이 원하는 답을 만들지 못한다는 **Alignment 문제** 가 있습니다. RLHF는 비교 데이터로부터 보상 모델을 학습한 뒤 강화 학습으로 LM을 정렬합니다. 본 포스터는 SFT → Reward Model → RL 최적화 의 3 단계를 정리합니다.


② Reward Model

STEP 2



같은 prompt의 출력 여러 개를 사람이 ranking한 **Human Comparison Dataset**으로 보상 모델 $RM_{\phi}(s)$ 를 학습한다. 학습된 RM은 RL 단계에서 **"어떤 답변이 더 선호되는지"**를 평가하는 보상 신호로 작동한다.

Σ / Pipeline 한눈에 보기



핵심 아이디어 — "정답 쓰기"는 비싸지만 "비교하기"는 싸다. 이 점을 활용해 비교 데이터로 보상 모델을 학습하고, 강화학습으로 LM에 **사람의 선호** 를 주입합니다.

인상 깊었던 점 — **최적화 목적 함수 자체를 사람의 가치에 맞게 재설계** 한다는 관점, 그리고 KL Penalty 한 줄의 정규화로 reward hacking을 막는 우아함.