

데이터 분석 및 EDA 스터디 2팀

조해웅(발표자), 노승현, 임선우, 최윤서

마이

스터디 소개

데이터 분석 및 EDA 스터디 2팀은 구성원 4명 모두 Basic Track이므로, Basic Track 과제에서 배운 지식을 여러 Kaggle 데이터셋에 적용하는 것을 목표로 스터디 진행함

각 데이터셋을 들여다보고, 여러 데이터 간의 상관관계 파악 및 분석을 진행하였으며, 스터디 후반부에는 추가로 머신러닝을 통한 예측까지 진행하였음

진행방식

1. 선정된 데이터셋을 각자 EDA 진행한다
2. 정기 스터디 시간에 각자 진행한 EDA를 발표한다
3. 공유된 방법 중 인상적인 내용을 추가로 적용해본다

데이터 분석 II

제목 : Steel Industry Energy Consumption



목표

철강 회사의 전력 소비 데이터를 활용하여, 메인 타겟인 전력소비량(Usage_kWh)과 다른 변수들 간의 상관관계를 탐색

데이터셋 소개

한국전력공사에 기록된 전력 소비량, 지상 무효전력, 진상 무효전력, CO2 농도, 지상 역률, 진상 역률, NSM, 날짜, 요일, 시간 등

분석 방법

I. EDA

시간대/요일/계절별 전력소비량 패턴 시각화(Bar plot, Box plot 등), 변수 간 상관관계를 Heat Map으로 시각화 등

II. 전처리

요일, 평일/주말 등 Label 인코딩


날짜 컬럼에서 시간, 월, 계절, 주말 여부 파생변수 생성

Standard Scaler로 수치형 변수 표준화

III. 모델링

다중 선형 회귀로 전력소비량 수치 예측

릿지, 라쏘, 엘라스틱넷 정규화 및 GridSearchCV로 최적 alpha 탐색



데이터 분석 I

제목 : Pokemon with stats



목표

1~6세대 포켓몬의 각 데이터를 바탕으로 능력치 예측, 세대 예측, 능력치 간의 상관관계 파악 등

데이터셋 소개

1~6세대의 포켓몬들의 도감번호, 타입, 능력치, 능력치의 합, 세대, 전설 여부 등

분석 방법

I. EDA

타입별/세대별 포켓몬 수 분포 시각화, 결측값 확인, 박스 플롯을 통한 전설과 일반 포켓몬 비교, 능력치 간 상관관계 Heat Map로 확인

II. 전처리

포켓몬 타입(Type 1, Type 2) 결측값 'None' 대체 및 label 인코딩
Standard Scaler로 능력치 표준화

전설여부(Legendary)->1/0으로 인코딩

II. 모델링

의사결정트리와 Random forest로 전설 세대 분류


K-means와 PCA로 군집화 및 시각화

주요 인사이트

1. 가장 강한 포켓몬 타입은?

$$\text{Avg Effectiveness} = \frac{\sum_{i=1}^{800} \text{공격 타입 vs 포켓몬의 배율}_i}{800}$$

$$\text{배율}_i = \text{상성(공격타입, Type1}_i) \times \text{상성(공격타입, Type2}_i)$$





➡ 가장 강한 타입은 바위 타입이다

2. 가장 강한 포켓몬이 많은 포켓몬 타입은?



➡ 드래곤 타입에 가장 강한 포켓몬이 많다

3. 능력치만 보고 몇 세대 포켓몬인지 예측 가능할까?



➡ 세대와 다른 변수와의 상관관계 약해 예측 불가능하다

데이터 분석 III

제목 : Store Sales - Time Series Forecasting



목표

에과도르 대형마트 Corporación Favorita의 매장별·상품군별 일일 판매량 예측 평가지표(RMSLE)

$$RMSLE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(1 + \hat{y}_i) - \log(1 + y_i))^2}$$

데이터셋 소개

train: 2013-01-01~2017-08-15 약 300만 데이터

(날짜, 매장번호, 판매량, 상품군, 행사상품 등)

test: 2017-08-16~2017-08-31 약 3만개 데이터

(train 데이터에서 판매량만 빠진 데이터)

Store: 매장의 위치, 유형, 판매 패턴을 갖는 메타데이터


Oil: 날짜별 유가 데이터

Holidays_events: 공휴일 및 이벤트 날짜 데이터**

분석 방법

I. 데이터 전처리

1. 결측치 처리 : 유가 데이터의 결측치는 시간적 연속성을 고려해 하루 전/후 데이터로 보충
2. 다중 소스 결합 : train 데이터에 oil, store, holiday_events 데이터를 날짜 및 지역 기준으로 병합
3. sales 데이터 로그 변환 : RMSLE 평가 지표에 최적화하기 위해 target data(sales)를 log1p 변환




II. 피처 엔지니어링

1. 이벤트 매칭 : 지역별, 국가별, 도시별 공휴일 및 이벤트 여부를 이진 변수로 생성하여 매출 변동 포착
2. 날짜 파생변수 생성 : 날짜 컬럼에서 요일·월·주차·주말 여부 등 시계열 패턴 포착을 위한 변수 추출

III. 모델링

1. 규칙 기반 베이스라인(최근 28일 평균) 먼저 설정 후 LightGBM과 성능 비교
2. 타겟을 log1p(sales)으로 변환하여 RMSLE 직접 최적화
3. 시계열 순서 유지한 validation 셋 분리(마지막 16일)
4. LightGBM early stopping 적용(200라운드 기준)



주요 인사이트

1. 시계열 데이터 분석: 판매 데이터가 주기적 패턴을 보유한다.
2. 도메인 지식의 중요성: 단순히 모델을 학습시키는 것이 아닌 도메인 지식을 통한 데이터 전처리 및 피처 엔지니어링이 중요하다.