

# 푸앙이와 즐기는 추천 시스템!

김찬중, 김승범, 노지우

# 푸앙이


## 스터디 소개

본 스터디는 Google Developer Program의 추천 시스템 학습 자료와 T-academy에서 제공하는 추천 시스템 강의를 기반으로 추천 시스템에 대한 전반적인 기초 지식을 학습하였습니다.  
콘텐츠 기반 필터링(Content-based Filtering), 협업 필터링(Collaborative Filtering) 등 추천 알고리즘의 동작 원리를 중심으로 학습하였으며, 사용자와 아이템 간의 관계를 기반으로 추천이 이루어지는 과정을 이해하는데 중점을 두었습니다.

## 주제 소개

머신러닝에서 추천 시스템은 사용자의 행동 데이터를 분석하여 개인에게 맞는 항목을 예측하고 제안하는 기술입니다.  
예를 들어 음악 스트리밍 서비스는 사용자가 자주 듣는 장르나 가수를 바탕으로 새로운 음악을 추천하고, 쇼핑몰은 이전에 구매하거나 조회한 상품과 비슷한 상품을 추천합니다. 이러한 추천은 사용자의 시청 기록, 구매 기록, 평점 등의 데이터를 기반으로 관심 있을 만한 항목을 예측하는 방식으로 이루어집니다.  
추천 시스템은 사용자와 아이템 간의 유사도를 계산하거나, 비슷한 취향을 가진 사용자들의 행동 패턴을 분석하여 더 적절한 추천 결과를 생성합니다. 대표적인 방식으로는 아이템의 특징을 기반으로 추천하는 Content-based Filtering과, 사용자들의 행동 패턴을 활용하는 Collaborative Filtering이 있습니다.

## 콘텐츠 기반 필터링



콘텐츠 기반 필터링(Content-based Filtering)은 사용자가 과거에 선호했던 아이템의 특징을 분석하여, 이와 유사한 아이템을 추천하는 방식이다.  
아이템의 장르, 카테고리, 키워드, 제작사 등의 feature를 바탕으로 사용자 프로필과 아이템 간의 유사도를 계산한다. 예를 들어 액션 영화를 자주 시청한 사용자에게 비슷한 장르나 키워드를 가진 다른 액션 영화를 추천할 수 있다.  
이 방식은 다른 사용자의 정보 없이도 추천이 가능하다는 장점이 있다. 하지만 기존 취향과 유사한 항목만 반복 추천될 수 있어 새로운 취향 발견에는 한계가 있다.

## 협업 필터링 & 행렬 분해

협업 필터링(Collaborative Filtering)은 사용자와 아이템 간의 상호작용 데이터를 기반으로 비슷한 취향의 사용자를 찾고, 그들이 선호한 아이템을 추천하는 방식이다.  
아이템의 특징을 직접 정의하지 않아도 사용자 행동 패턴을 통해 선호 관계를 학습할 수 있으며, 피드백 행렬만으로 추천을 시작할 수 있다는 장점이 있다. 또한 사용자가 기존에 접하지 않았던 새로운 관심사를 발견하는 데 도움을 줄 수 있다.  
반면 신규 사용자나 신규 아이템처럼 상호작용 데이터가 부족한 경우 Cold Start 문제가 발생할 수 있고, 나이·지역·카테고리와 같은 Side Feature를 직접 반영하기 어렵다는 한계가 있다.

## 심층 신경망 추천 모델

**[왜 DNN인가? — MF의 한계 극복]** 행렬 분해(MF)의 두 가지 핵심 한계는 Side Feature 사용 불가(사용자 ID / 아이템 ID 이외의 정보 (나이, 국가 등) 반영 어려움) 과 Popularity Bias(인기 아이템이 모든 사용자에게 추천되는 경향)이다. DNN은 입력층의 유연성으로 두 문제를 모두 해결한다.

**[Softmax DNN 구조]** 문제를 다중 클래스 분류로 정의한다.

$$\hat{p} = h(\psi(x)V^T), \quad h(y)_i = \frac{e^{y_i}}{\sum_j e^{y_j}}$$

- 입력 ( $x$ ): Dense feature + Sparse feature
- 은닉층( $\psi(x)$ ): ReLU로 복잡한 관계 포착
- 출력( $\hat{p}$ ): 모든 아이템에 대한 확률 분포
- 손실함수: Cross-Entropy( $\hat{p}$  vs  $p$ )

**[Softmax 임베딩]**

- : 마지막 은닉층 출력 → 쿼리 임베딩
- $V_j$ : Softmax가중치 행렬 j번째 행 → 아이템 임베딩
- MF와 달리 쿼리 임베딩을 비선형 함수  $\psi(\cdot)$ 로 학습

**[Two-Tower, Folding & MF vs DNN]**

Two-Tower는 쿼리·아이템 탑이 각각 임베딩을 출력한 뒤 내적으로 점수를 예측한다. Positive만 학습하면 다른 그룹 임베딩이 같은 공간에 뭉치는 Folding이 발생하므로, Negative Sampling (균등 또는 Hard Negative)으로 방지한다. MF는 대규모 후보 생성에, DNN은 개인화 정밀 스코어링에 적합하다.

